



Institut National de Statistique
et d'Économie Appliquée

RAPPORT DE PROJET

Analyse et prévision d'une série chronologique

La consommation de gaz au Royaume-Uni

RÉALISÉ PAR

Fatima ezzahrae ELKHADAOUY
Manar HOUIOUA

SOUS LA DIRECTION DE

Mme. Fadoua BADAOUI

Table des matières

Chapitre 1 : Introduction	5
1.1 Contexte et présentation des données	5
1.2 Problématique	5
1.3 Objectifs et méthodologie	5
 Chapitre 2 : Préparation des données	6
2.1 Description de la série	6
2.2 Chargement et création de la série	6
2.3 Datation de la série	6
2.4 Division des données	7
 Chapitre 3 : Etude des caractéristiques de la série	8
3.1 Représentation graphique de la série brute	8
3.2 Analyse de la tendance	9
3.2.1 Autocorrélogramme simple	9
3.2.2 Autocorrélogramme partiel	10
3.2.3 Test de Fisher pour la tendance	11
3.3 Analyse de la saisonnalité	12
3.3.1 Autocorrélogramme simple saisonnier	12
3.3.2 Autocorrélogramme partiel saisonnier	13
3.3.3 Test de Fisher pour la saisonnalité	14
 Chapitre 4 : Test de stationnarité	15
4.1 Autocorrélogramme simple	15
4.1 Autocorrélogramme partiel	16
4.2 Test de Dickey-Fuller Augmenté	17
4.3 Test KPSS	18

Chapitre 5 : Stationnarisation de la série	19
5.1 Transformation logarithmique	19
5.2 Différenciation de la série	20
5.2.1 Différenciation d ordre 1	20
5.2.2 Différenciation saisonnière d ordre 1	20
5.3 Vérification de la stationnarité	21
5.3.1 Autocorrélogramme	21
5.3.2 Test de Dickey-Fuller augmenté	22
5.3.3 Test KPSS	22
 Chapitre 6 : Identification du modèle	 23
6.1 Analyse des ACF et PACF	23
6.2 Test de Bartlett	24
6.3 Modèles candidats	24
 Chapitre 7 : Estimation du modèle	 25
7.1 Estimation des paramètres	25
7.2 Test de Student	25
7.3 Sélection des modèles significatifs	26
 Chapitre 8 : Validation du modèle	 27
8.1 Analyse graphique des résidus	27
8.2 Test de bruit blanc	28
8.3 Normalité des résidus	28
8.4 Critères AIC et BIC	29
 Chapitre 9 : Prévision	 30
9.1 Prévision sur la série log	30
9.2 Prévision en valeurs originales	31
9.3 Evaluation des performances	31

Chapitre 10 : Conclusion générale	32
Annexe : Code R complet	33-37

Chapitre 1 : Introduction

1.1 Contexte et présentation des données

Dans cette analyse, on souhaite comprendre les caractéristiques et réaliser des prévisions concernant la consommation de gaz au **Royaume-Uni**. La série **UKgas** est un indicateur clé de la consommation énergétique au Royaume-Uni, reflétant les comportements de chauffage et les variations saisonnières dues aux conditions météorologiques.

Les données utilisées dans cette étude sont directement disponibles dans le logiciel **R** grâce au jeu de données **UKgas**, sans avoir besoin d'importer de fichier externe. La série s'étend du premier trimestre 1960 au quatrième trimestre 1986, soit **108 observations trimestrielles** consécutives, exprimées en millions de therms.

1.2 Problématique

Cette analyse vise tout d'abord à saisir la dynamique intrinsèque de la série **UKgas** afin de concevoir un modèle de prévision performant. Car la consommation de gaz présente une forte saisonnalité trimestrielle et une tendance à la hausse, ce qui pose un défi au statisticien.

Question essentielle : Dans quelle mesure une modélisation sous forme de processus SARIMA peut-elle être utilisée pour faire des prédictions sur la consommation de gaz au Royaume-Uni ?

1.3 Objectifs et méthodologie

Pour résoudre la problématique posée précédemment, on mettra en place une méthode d'analyse de série temporelle. Cette méthode sera séparée en trois parties principales :

- **Analyse exploratoire** : Nous examinerons la série en question pour identifier la tendance, la saisonnalité et les éventuels changements structurels.
- **Modélisation** : Nous mettrons en œuvre la stationnarisation de la série par transformation logarithmique et différenciation, et identifierons les modèles les plus pertinents à l'aide des fonctions d'autocorrélation (ACF/PACF).
- **Validation** : L'efficacité de nos prédictions sera vérifiée par une analyse de type Apprentissage/Validation, en utilisant les indicateurs RMSE et MAPE.

Chapitre 2 : Préparation des données

2.1 Description de la série

La série étudiée représente la consommation de gaz au **Royaume-Uni** par trimestre pour la période allant du **premier trimestre 1960 au quatrième trimestre 1986** (108 observations trimestrielles exprimées en millions de therms). Les données sont directement disponibles dans le logiciel R avec le nom de jeu de données UKgas.

2.2 Chargement et création de la série

Le logiciel R propose directement la série UKgas sans avoir besoin d'importer un fichier externe. Nous avons chargé la série, puis nous l'avons convertie en un objet série temporelle(ts) avec une fréquence de **quatre trimestres** par an. Cela correspond parfaitement à la nature trimestrielle des données de la série UKgas.

2.3 Datation de la série

La datation de la série consiste à associer à chaque observation son trimestre réel. La série commence au premier trimestre de l'année 1960 et se termine au quatrième trimestre de l'année 1986, Cela représente une période de **27 années** de données trimestrielles consécutives.

Date	Consommation
1960 T1	160.1
1960 T2	129.7
1960 T3	84.8
1960 T4	120.1
	⋮
1986 T1	1163.9
1986 T2	613.1
1986 T3	347.4
1986 T4	782.8

TABLE 1 – Série UKgas avec datation

2.4 Division des données

Afin de modéliser et valider les prévisions, la série UKgas a été divisée en deux parties. Les 86 premières observations, de 1960 T1 à 1981 T2, soit environ 80 % de la série, ont servi à l'**apprentissage** du modèle. Elles ont permis d'estimer les paramètres du modèle. Les 22 autres observations, de 1981 T3 à 1986 T4, soit les 20 % les plus récents, ont constitué la base de **test**. Celle-ci a été utilisée pour l'évaluation hors échantillon.


	Apprentissage	Validation
Période	1960 T1 – 1981 T2	1981 T3 – 1986 T4
Observations	86	22
Pourcentage	80%	20%

TABLE 2 – Division de la série UKgas

Chapitre 3 : Etude des caractéristiques de la série

3.1 Représentation graphique de la série brute


La représentation graphique de la série UKgas sur la période de 1960 à 1986 montre plusieurs choses importantes. On voit clairement que la consommation **augmente** tout au long de la période, passant d'environ 160 millions de therms en 1960 à plus de 1163 millions de therms en 1986. De plus, il y a **une saisonnalité** qui se répète tous les **trimestres**, avec des consommations plus élevées en hiver et des consommations plus basses en été, et l'amplitude des fluctuations saisonnières augmente progressivement avec le temps, ce qui signifie que **la variance** de la série UKgas n'est pas **constante**. Ces observations montrent que la série UKgas n'est pas stationnaire et qu'il est nécessaire de la transformer avant de pouvoir la modéliser.



3.2 Analyse de la tendance


3.2.1 Autocorrélogramme simple

L'analyse de la fonction d'autocorrélation montre que les autocorrélations sont toutes très élevées et diminuent très lentement vers zéro. C'est un comportement typique d'une série qui présente une **forte tendance** et cela confirme que la série UKgas **n'est pas stationnaire**.



3.2.2 Autocorrélogramme partiel

La fonction d'autocorrélation partielle montre des pics importants aux premiers décalages, soit 1, 2, 3 et 4. Ensuite, les valeurs diminuent petit à petit. Cela confirme qu'il y a **une tendance** dans les données de la série UKgas.



3.2.3 Test de Fisher pour la tendance

Pour confirmer ces observations graphiques, nous utilisons le test de Fisher basé sur l'analyse de la variance. Les hypothèses du test de Fisher sont :

- H_0 : pas d'influence du facteur année (pas de tendance)
- H_1 : influence significative du facteur année (tendance)

Source	Ddl	Somme des carrés	F empirique	p-value
Année (tendance)	26	4 019 048	10.58	2.28×10^{-16}
Résidus	78	1 139 134	—	—

TABLE 3 – Test de Fisher pour la tendance


La p-value est inférieure à 2.28×10^{-16} , ce qui est bien en dessous du seuil de 5 %. Par conséquent, on rejette H_0 . Cela signifie que la série UKgas a une **tendance croissante très significative**. Celle-ci devra être éliminée lors de l'étape de stationnarisation.

Conclusion : Les outils utilisés pour analyser la tendance montrent tous la même chose. Les fonctions d'autocorrélation ACF et PACF ainsi que le test de Fisher convergent vers la même conclusion. La série UKgas a une **tendance croissante** qui est fortement significative ($F = 10.58$, $p\text{-value} = 2.28 \times 10^{-16} < 0.05$). On peut voir cette tendance dans la façon dont les autocorrélations diminuent lentement et dans les pics significatifs aux premiers lags de la PACF. Pour que la série soit stationnaire, il faudra éliminer cette tendance en utilisant une différenciation d'ordre 1.

3.3 Analyse de la saisonnalité


3.3.1 Autocorrélogramme simple saisonnier

L'analyse de la fonction d'autocorrélation calculée sur 48 lags montre des pics significatifs aux lags 4, 8, 12, 16, 20 et 24. Ces pics correspondent exactement aux multiples de la période trimestrielle. La série étudiée présente donc un comportement périodique très régulier. Ce type de comportement est caractéristique d'une série avec une **saisonnalité trimestrielle** fortement marquée.



3.3.2 Autocorrélogramme partiel saisonnier

La fonction d'autocorrélation partielle montre des pics significatifs aux décalages 1, 2, 3, 4 et 6. Le pic à 4 confirme qu'il y a **une saisonnalité** trimestrielle dans la série UKgas.



3.3.3 Test de Fisher pour la saisonnalité

Pour confirmer ces observations graphiques, nous utilisons le test de Fisher basé sur l'analyse de la variance. Les hypothèses du test de Fisher sont :

- H_0 : pas d'influence du facteur période (pas de saisonnalité)
- H_1 : influence significative du facteur période (saisonnalité)

Source	Ddl	Somme des carrés	F empirique	p-value
Période (saisonnalité)	3	1 600 920	36.54	7.47×10^{-15}
Résidus	78	1 139 134	—	—

TABLE 4 – Test de Fisher pour la saisonnalité


La p-value vaut 7.47×10^{-15} , ce qui est nettement inférieur au seuil de 5%. Par conséquent, nous rejetons l'hypothèse nulle, notée H_0 . Le facteur période est **significatif**, ce qui confirme qu'il existe une **saisonnalité trimestrielle très marquée** dans la série UKgas. La valeur élevée de la statistique de Fisher, qui est de 36,54, montre à quel point cet effet saisonnier est important.

Conclusion : Les outils utilisés confirment tous la présence d'une **saisonnalité trimestrielle très significative** dans la série UKgas. Le résultat du test est $F = 36,54$ et la p-value est $= 7.47 \times 10^{-15} < 0.05$, ce qui est inférieur à 0,05. Les pics dans les fonctions de corrélation, à des intervalles de 4, confirment également cette saisonnalité. Pour stationnariser la série, il faudra éliminer cette saisonnalité en utilisant une différenciation saisonnière d'ordre 1.

Chapitre 4 : Test de stationnarité de la série


4.1 Autocorrélogramme simple

L'analyse de la fonction d'autocorrélation (ACF) de la série d'apprentissage montre que les autocorrélations sont très élevées. Elles diminuent lentement pour atteindre zéro. ainsi, On note des pics significatifs aux lags 4, 8, 12 et 16. Ces lags correspondent à des multiples de la période trimestrielle. Ce comportement confirme que la série d'apprentissage UKgas **n'est pas stationnaire**.



4.2 Autocorrélogramme partiel

La fonction d'autocorrélation partielle (PACF) présente des pics significatifs aux lags 1, 2 et 3. Cela confirme que la série d'apprentissage UKgas n'est **pas stationnaire**.



4.3 Test de Dickey-Fuller Augmenté (ADF)

Le test de Dickey-Fuller Augmenté (ADF) permet de tester formellement la stationnarité de la série. Les hypothèses du test sont les suivantes :

- H_0 : la série possède une racine unitaire (non stationnaire)
- H_1 : la série est stationnaire

Augmented Dickey-Fuller Test

```
data: train
Dickey-Fuller = -1.2552, Lag order = 4, p-value = 0.8818
alternative hypothesis: stationary
```

FIGURE 1 – Résultats du test de Dickey-Fuller augmenté

La p-value est de 0.8818, ce qui est nettement supérieur au seuil de 5%. Par conséquent, on ne rejette pas l'hypothèse nulle, notée H_0 . La série d'apprentissage UKgas est considérée comme **non stationnaire**.

4.4 Test KPSS

Le test KPSS permet de confirmer les résultats du test ADF. Les hypothèses du test sont les suivantes :

- H_0 : la série est stationnaire
- H_1 : la série possède une racine unitaire (non stationnaire)

```
KPSS Test for Level Stationarity

data:  train
KPSS Level = 2.0705, Truncation lag parameter = 3, p-value = 0.01
```

FIGURE 2 – Résultats du test KPSS de stationnarité

La p-value est de 0.01, ce qui est nettement inférieur au seuil de 5%. Par conséquent, on rejette l'hypothèse nulle, notée H_0 . La série d'apprentissage UKgas est considérée comme **non stationnaire**, ce qui confirme les résultats que nous avons obtenus avec le test ADF.


Conclusion : Tous les tests que nous avons réalisés, tels que l'autocorrelogramme, le test ADF et le test KPSS, montrent clairement que la série d'apprentissage DAX est **non-stationnaire**. Par conséquent, il est essentiel de rendre cette série stationnaire avant de procéder à toute modélisation.

Chapitre 5 : Stationnarisation de la série

5.1 Transformation logarithmique

La série d'apprentissage UKgas montre des fluctuations saisonnières de plus en plus grandes au fil du temps et une variance non constante. Pour stabiliser ces variations, on utilise une transformation logarithmique :

$$Y_t = \log(X_t)$$



Après avoir appliqué une transformation logarithmique, nous constatons que la variance de la série temporelle est devenue beaucoup plus **stable** et homogène sur toute la période étudiée. La tendance de la série est toujours présente, mais les fluctuations qui apparaissent sont maintenant plus régulières et prévisibles.

5.2 Différenciation de la série

5.2.1 Différenciation d'ordre 1


Afin d'éliminer la tendance, on applique une différenciation d'ordre 1 à la série logarithmique :

$$\Delta Y_t = \log(X_t) - \log(X_{t-1})$$

5.2.2 Différenciation saisonnière d'ordre 1

Pour éliminer la saisonnalité qui se produit tous les quatre mois, nous appliquons ensuite une différenciation saisonnière d'ordre 1 de lag 4 mois la série de données qui a déjà été différenciée.

$$\begin{aligned}\Delta_4 \Delta Y_t &= \Delta Y_t - \Delta Y_{t-4} \\ &= [\log(X_t) - \log(X_{t-1})] - [\log(X_{t-4}) - \log(X_{t-5})]\end{aligned}$$





Après la différenciation, la série semble flotter autour de zéro. Elle ne présente pas de tendance claire et sa variance paraît constante, ceci indique que la série est **stationnaire**.

5.3 Vérification de la stationnarité

5.3.1 Autocorrélogramme

Les fonctions ACF et PACF de la série transformée montrent que la plupart des autocorrélations se situent à l'intérieur des intervalles de confiance à 95%, ce qui indique que la série peut être considérée comme **stationnaire**.



5.3.2 Test de Dickey-Fuller augmenté

```
Augmented Dickey-Fuller Test

data:  train_log_diff1_4
Dickey-Fuller = -6.8134, Lag order = 4, p-value = 0.01
alternative hypothesis: stationary
```

FIGURE 3 – Résultats du test de Dickey-Fuller augmenté

— La p-value est égale à $0.01 < 0.05$. On rejette H_0 , la série log différenciée est **stationnaire**.

5.3.3 Test KPSS

```
KPSS Test for Level Stationarity

data:  train_log_diff1_4
KPSS Level = 0.022792, Truncation lag parameter = 3, p-value =
0.1
```

FIGURE 4 – Résultats du test KPSS


— La p-value est égale à $0.01 > 0.05$. On ne rejette pas H_0 , la série log différenciée est **stationnaire**.

Conclusion : La série UKgas a été rendue **stationnaire** en combinant la transformation logarithmique, la différenciation d'ordre 1 et la différenciation saisonnière d'ordre 1. Les tests ADF et KPSS donnent unanimement des résultats qui confirment la stationnarité de la série. ainsi, Le modèle retenu est un modèle **SARIMA(p,1,q)(P,1,Q)[4]**.


Chapitre 6 : Identification du modèle

6.1 Analyse des ACF et PACF

L'ACF présente des pics significatifs aux lags 2 et 5, ce qui suggère une composante MA d'ordre 2 pour la partie non saisonnière et une composante MA saisonnière d'ordre 1.



La PACF montre des pics significatifs aux lags 1, 2, 4 et 8. Cela suggère que la partie non saisonnière a une composante AR d'ordre 2 et que la composante AR saisonnière est également d'ordre 2.



Donc $p_{max} = 2$, $q_{max} = 2$, $P_{max} = 2$ et $Q_{max} = 1$.

6.2 Test de Bartlet

Le test de Bartlet est utilisé pour déterminer avec précision les valeurs spécifiques de p, q, P et Q. Pour calculer la borne de Bartlet, il faut suivre une procédure spécifique. La borne de Bartlet est calculée de la manière suivante :

$$\pm \frac{z_{\alpha/2}}{\sqrt{T}} = \pm \frac{2}{\sqrt{81}} = \pm 0.2222$$

Fonction	Lags significatifs	Interpretation
ACF	1, 2, 5, 6	q_max = 2, Q_max = 1
PACF	1, 2, 4, 8	p_max = 2, P_max = 2

TABLE 5 – Resultats du test de Bartlet

6.3 Modèles candidats

Sur la base des analyses des fonctions d'autocorrélation (ACF), des fonctions d'autocorrélation partielle (PACF) et du test de Bartlet, voici les modèles candidats qui ont été retenus :

Modèle	Paramètres
SARIMA(1,1,1)(1,1,1)[4]	p=1, q=1, P=1, Q=1
SARIMA(2,1,1)(1,1,1)[4]	p=2, q=1, P=1, Q=1
SARIMA(1,1,2)(1,1,1)[4]	p=1, q=2, P=1, Q=1
SARIMA(2,1,2)(1,1,1)[4]	p=2, q=2, P=1, Q=1
SARIMA(0,1,1)(0,1,1)[4]	p=0, q=1, P=0, Q=1
SARIMA(1,1,1)(0,1,1)[4]	p=1, q=1, P=0, Q=1
SARIMA(0,1,2)(0,1,1)[4]	p=0, q=2, P=0, Q=1

TABLE 6 – Modèles candidats SARIMA

Conclusion : Sur la base de l'analyse des fonctions ACF et PACF et du test de Bartlet, nous sélectionnons 7 modèles candidats de type SARIMA(p,1,q)(P,1,Q)[4] . Ces sept modèles candidats seront estimés et comparés dans le chapitre suivant.

Chapitre 7 : Estimation du modèle

7.1 Test de Student

Le test de Student est utilisé pour vérifier si chaque coefficient estimé est significatif. Un coefficient est considéré comme **significatif** si $|t| > 1.96$ au seuil de 5%. Les résultats détaillés pour chaque modèle sont présentés ci-dessous :

Modèle	Coefficients	$ t > 1.96$	Tous significatifs
SARIMA(1,1,1)(1,1,1)[4]	ar1, ma1, sar1, sma1	ar1, ma1	Non
SARIMA(2,1,1)(1,1,1)[4]	ar1, ar2, ma1, sar1, sma1	ar1, ma1	Non
SARIMA(1,1,2)(1,1,1)[4]	ar1, ma1, ma2, sar1, sma1	ma1, ma2	Non
SARIMA(2,1,2)(1,1,1)[4]	ar1, ar2, ma1, ma2, sar1, sma1	ma1	Non
SARIMA(0,1,1)(0,1,1)[4]	ma1, sma1	ma1, sma1	Oui
SARIMA(1,1,1)(0,1,1)[4]	ar1, ma1, sma1	ar1, ma1	Non
SARIMA(0,1,2)(0,1,1)[4]	ma1, ma2, sma1	ma1, ma2, sma1	Oui

TABLE 7 – Test de Student pour chaque modèle

7.2 Estimation des AIC et BIC

Pour chaque modèle candidat identifié au chapitre précédent, nous estimons les paramètres du modèle candidat par la méthode du **maximum de vraisemblance**. Les résultats du modèle candidat sont présentés dans le tableau suivant :

Modèle	AIC	BIC
SARIMA(1,1,1)(1,1,1)[4]	-116.70	-104.73
SARIMA(2,1,1)(1,1,1)[4]	-117.70	-103.33
SARIMA(1,1,2)(1,1,1)[4]	-118.41	-104.04
SARIMA(2,1,2)(1,1,1)[4]	-117.30	-100.54
SARIMA(0,1,1)(0,1,1)[4]	-116.93	-109.74
SARIMA(1,1,1)(0,1,1)[4]	-118.58	-109.00
SARIMA(0,1,2)(0,1,1)[4]	-120.64	-111.06

TABLE 8 – Estimation des AIC et BIC

7.3 Sélection des modèles significatifs

Après avoir appliqué le test de Student, seuls les modèles dont **tous les coefficients sont significatifs** sont retenus pour la validation :


- **SARIMA(0,1,1)(0,1,1)[4]** : AIC = -116.93, BIC = -109.74
- **SARIMA(0,1,2)(0,1,1)[4]** : AIC = -120.64, BIC = -111.06

Conclusion : Deux modèles ont tous leurs coefficients qui sont significatifs au seuil de 5 %. Nous allons valider ces deux modèles dans le chapitre suivant pour choisir le meilleur.


Chapitre 8 : Validation du modèle

8.1 Analyse graphique des résidus

SARIMA(0,1,1)(0,1,1)[4] :



SARIMA(0,1,2)(0,1,1)[4] :



Les résidus des deux modèles varient autour de zéro, et il n'y a pas de structure apparente. Cependant, il y a quelques pics en 1971-1972, ce qui est dû au choc pétrolier.

8.2 Test de bruit blanc

Test de Box-Pierce et Ljung-Box :

Les hypothèses des tests sont :

- H_0 : les résidus sont un bruit blanc
- H_1 : les résidus ne sont pas un bruit blanc

Modèle	Test	Statistique	p-value
SARIMA(0,1,1)(0,1,1)[4]	Box-Pierce	15.351	0.7560
	Ljung-Box	16.808	0.6654
SARIMA(0,1,2)(0,1,1)[4]	Box-Pierce	10.487	0.9584
	Ljung-Box	11.813	0.9224

TABLE 9 – Tests de bruit blanc

Les p-values des deux modèles sont supérieures à 0.05. On ne rejette pas l'hypothèse nulle H_0 . Les résidus des deux modèles constituent un **bruit blanc**.

8.3 Normalité des résidus

Test de Shapiro-Wilk :

Les hypothèses du test sont :

- H_0 : les résidus suivent une loi normale
- H_1 : les résidus ne suivent pas une loi normale

Modèle	Statistique W	p-value	Normalité
SARIMA(0,1,1)(0,1,1)[4]	0.82224	8.787×10^{-9}	Non
SARIMA(0,1,2)(0,1,1)[4]	0.88474	1.426×10^{-6}	Non

TABLE 10 – Test de normalité de Shapiro-Wilk

Les p-values des deux modèles sont inférieures à 0,05. On doit donc rejeter l'hypothèse nulle, qui est notée H_0 . Les résidus des deux modèles ne suivent **pas une loi normale**. Cette non-normalité est due aux pics exceptionnels qui se sont produits en 1971 et 1972, et qui sont liés au choc pétrolier.

8.4 Critères AIC et BIC

Modèle	AIC	BIC	Sélection
SARIMA(0,1,1)(0,1,1)[4]	-116.93	-109.74	
SARIMA(0,1,2)(0,1,1)[4]	-120.64	-111.06	Retenu


TABLE 11 – Comparaison des critères AIC et BIC

Conclusion : Les deux modèles valident le test de bruit blanc. Le modèle **SARIMA(0,1,2)(0,1,1)[4]** est retenu car il présente l'AIC (-120.64) et le BIC (-111.06) les plus bas, indiquant un meilleur ajustement aux données.

Chapitre 9 : Prédiction


9.1 Prédiction sur la série log

Le modèle **SARIMA(0,1,2)(0,1,1)[4]** est utilisé pour prévoir la consommation de gaz au Royaume-Uni. Cette prévision est effectuée sur la période de validation, qui s'étend de 1981 T3 à 1986 T4. Cette période de validation couvre un total de **22 trimestres**.



Le graphique indique que le modèle reflète avec précision la tendance croissante et la saisonnalité qui se produit tous les trimestres dans la série. On observe que les intervalles de confiance deviennent de plus en plus larges à mesure que l'horizon de prévision s'allonge.

9.2 Prédiction en valeurs originales



Les prévisions du modèle SARIMA suivent très fidèlement les valeurs réelles de la consommation de gaz au Royaume-Uni. Le modèle capture parfaitement la saisonnalité trimestrielle de la consommation de gaz. Les valeurs réelles de la consommation de gaz au Royaume-Uni sont très bien représentées par les prévisions du modèle SARIMA.

9.3 Evaluation des performances

Critère	Valeur
RMSE	49.55
MAPE	8.20%

TABLE 12 – Critères d'évaluation des prévisions

Conclusion : Le modèle **SARIMA(0,1,2)(0,1,1)[4]** donne d'excellentes prévisions. Il a un **MAPE de 8.20%** et un **RMSE de 49.55**. Ces résultats montrent que le modèle **SARIMA(0,1,2)(0,1,1)[4]** est capable de capturer fidèlement la tendance croissante et la saisonnalité trimestrielle de la série UKgas.

Chapitre 10 : Conclusion

Ce rapport vise à examiner et à prédire la consommation de gaz chaque trimestre au Royaume-Uni en utilisant la méthode de Box-Jenkins. Tout d'abord, une analyse a été effectuée pour voir comment la consommation de gaz a évolué. Il a été constaté que la consommation de gaz augmentait et que les périodes de l'année avaient un impact important. Pour que les données soient plus faciles à analyser, la consommation de gaz a été calculée différemment en utilisant des logarithmes et en faisant une double différenciation.

Le modèle **SARIMA(0,1,2)(0,1,1)[4]** a été sélectionné comme le modèle le plus approprié. Ce modèle présente l'avantage d'avoir tous ses coefficients significatifs. De plus, il possède les critères AIC et BIC les plus bas, avec des valeurs respectives de -120,64 et -111,06. Les résultats des prévisions obtenues avec ce modèle sont très satisfaisants, avec un **MAPE de 8,20 %**. Cela confirme que le modèle **SARIMA(0,1,2)(0,1,1)[4]** est capable de capturer avec précision la tendance et la saisonnalité de la série UKgas.

Annexe : Code R complet

```
1  # INSTALLATION DES PACKAGES
2  install.packages("tseries")
3  install.packages("zoo")
4  install.packages("forecast")
5  install.packages("lmtest")
6  install.packages("randtests")
7
8  # CHARGEMENT DES BIBLIOTHEQUES
9  library(tseries)
10 library(zoo)
11 library(forecast)
12 library(lmtest)
13 library(randtests)
14
15 # CHARGEMENT DES DONNEES
16 data("UKgas")
17
18 # INFORMATIONS SUR LA SERIE
19 cat("Debut      :", start(UKgas), "\n")
20 cat("Fin        :", end(UKgas), "\n")
21 cat("Frequence   :", frequency(UKgas), "\n")
22 cat("Observations :", length(UKgas), "\n")
23 summary(UKgas)
24
25 # CREATION DE LA SERIE TEMPORELLE
26 ukgas.ts <- ts(UKgas, start = c(1960, 1), frequency = 4)
27
28 # DATATION DE LA SERIE
29 D <- as.Date(as.yearmon(time(ukgas.ts)))
30 ukgas.df <- data.frame(Date = D,
31                        Valeur = as.numeric(ukgas.ts))
32 ukgas.aperçu <- rbind(head(ukgas.df, 4), tail(ukgas.df, 4))
33 print(ukgas.aperçu, row.names = FALSE)
34
35 # DIVISION 80% APPRENTISSAGE / 20% VALIDATION
36 n <- length(ukgas.ts)
37 n_train <- round(0.8 * n)
38 n_test <- n - n_train
39 train <- window(ukgas.ts, end = time(ukgas.ts)[n_train])
40 test <- window(ukgas.ts, start = time(ukgas.ts)[n_train + 1])
41
42 # REPRESENTATION GRAPHIQUE
43 png("ukgas_brut.png", width = 800, height = 500)
44 plot(ukgas.ts, type = "l", col = "green",
45      main = "Consommation de gaz au Royaume-Uni (1960-1986)",
46      xlab = "Temps",
47      ylab = "Consommation (millions de therms)")
48 dev.off()
49
50
51
```

```

52
53 # ACF ET PACF DE LA SERIE BRUTE
54 png("acf_ukgas.png", width = 800, height = 500)
55 plot(acf(as.numeric(ukgas.ts), lag.max = 36, plot = FALSE),
56      ylim = c(-1, 1),
57      main = "ACF de la serie UKgas brute")
58 dev.off()
59
60 png("pacf_ukgas.png", width = 800, height = 500)
61 plot(pacf(as.numeric(ukgas.ts), lag.max = 36, plot = FALSE),
62      ylim = c(-1, 1),
63      main = "PACF de la serie UKgas brute")
64 dev.off()
65
66 # TEST DE FISHER
67 x <- as.numeric(ukgas.ts)
68 N <- 27
69 p <- 4
70 annee <- rep(1:N, each = p)[1:length(x)]
71 periode <- rep(1:p, times = N)[1:length(x)]
72 ukgas.anova <- data.frame(valeur = x,
73                           annee = as.factor(annee),
74                           periode = as.factor(periode))
75 model.anova <- aov(valeur ~ annee + periode, data = ukgas.anova)
76 summary(model.anova)
77
78 # ACF PACF SAISONNALITE
79 png("acf_ukgas_saisonnalite.png", width = 800, height = 500)
80 plot(acf(as.numeric(ukgas.ts), lag.max = 48, plot = FALSE),
81      ylim = c(-1, 1),
82      main = "ACF de la serie UKgas - Detection de la saisonnalite")
83 dev.off()
84
85 png("pacf_ukgas_saisonnalite.png", width = 800, height = 500)
86 plot(pacf(as.numeric(ukgas.ts), lag.max = 48, plot = FALSE),
87      ylim = c(-1, 1),
88      main = "PACF de la serie UKgas - Detection de la saisonnalite")
89 dev.off()
90
91 # CHAPITRE 4 : TEST DE STATIONNARITE
92 png("acf_train_ukgas.png", width = 800, height = 500)
93 plot(acf(as.numeric(train), lag.max = 36, plot = FALSE),
94      ylim = c(-1, 1),
95      main = "ACF de la serie d apprentissage UKgas")
96 dev.off()
97
98 png("pacf_train_ukgas.png", width = 800, height = 500)
99 plot(pacf(as.numeric(train), lag.max = 36, plot = FALSE),
100      ylim = c(-1, 1),
101      main = "PACF de la serie d apprentissage UKgas")
102 dev.off()
103
104 adf.test(train)

```

```

105 kpss.test(train)
106
107 # CHAPITRE 5 : STATIONNARISATION
108 train_log <- log(train)
109
110 png("ukgas_train_log.png", width = 800, height = 500)
111 plot(train_log, type = "l", col = "green",
112       main = "Serie d apprentissage UKgas apres transformation log",
113       xlab = "Temps", ylab = "log(UKgas)")
114 dev.off()
115
116 train_log_diff1 <- diff(train_log, differences = 1)
117 train_log_diff1_4 <- diff(train_log_diff1, lag = 4, differences = 1)
118
119 png("ukgas_stationnaire.png", width = 800, height = 500)
120 plot(train_log_diff1_4, type = "l", col = "green",
121       main = "Serie UKgas apres transformation log et double differenciation",
122       xlab = "Temps", ylab = "Valeur")
123 dev.off()
124
125 png("acf_ukgas_stat.png", width = 800, height = 500)
126 plot(acf(as.numeric(train_log_diff1_4), lag.max = 36, plot = FALSE),
127       ylim = c(-1, 1),
128       main = "ACF de la serie UKgas stationnaire")
129 dev.off()
130
131 png("pacf_ukgas_stat.png", width = 800, height = 500)
132 plot(pacf(as.numeric(train_log_diff1_4), lag.max = 36, plot = FALSE),
133       ylim = c(-1, 1),
134       main = "PACF de la serie UKgas stationnaire")
135 dev.off()
136
137 adf.test(train_log_diff1_4)
138 kpss.test(train_log_diff1_4)
139
140 # CHAPITRE 6 : IDENTIFICATION
141 T <- length(train_log_diff1_4)
142 borne <- 2 / sqrt(T)
143 cat("Borne de Bartlett :", borne, "\n")
144 acf_vals <- acf(as.numeric(train_log_diff1_4), lag.max = 36, plot = FALSE)
145 pacf_vals <- pacf(as.numeric(train_log_diff1_4), lag.max = 36, plot = FALSE)
146 cat("Lags ACF significatifs :\n")
147 print(which(abs(acf_vals$acf) > borne))
148 cat("Lags PACF significatifs :\n")
149 print(which(abs(pacf_vals$acf) > borne))
150
151 # CHAPITRE 7 : ESTIMATION
152 model1 <- Arima(train_log, order = c(1,1,1),
153                 seasonal = list(order = c(1,1,1), period = 4))
154 coeftest(model1)
155 cat("AIC model1 :", AIC(model1), "\n")

```

```

156 cat("BIC model1 :", BIC(model1), "\n\n")
157
158 model2 <- Arima(train_log, order = c(2,1,1),
159               seasonal = list(order = c(1,1,1), period = 4))
160 coeftest(model2)
161 cat("AIC model2 :", AIC(model2), "\n")
162 cat("BIC model2 :", BIC(model2), "\n\n")
163
164 model3 <- Arima(train_log, order = c(1,1,2),
165               seasonal = list(order = c(1,1,1), period = 4))
166 coeftest(model3)
167 cat("AIC model3 :", AIC(model3), "\n")
168 cat("BIC model3 :", BIC(model3), "\n\n")
169
170 model4 <- Arima(train_log, order = c(2,1,2),
171               seasonal = list(order = c(1,1,1), period = 4))
172 coeftest(model4)
173 cat("AIC model4 :", AIC(model4), "\n")
174 cat("BIC model4 :", BIC(model4), "\n\n")
175
176 model5 <- Arima(train_log, order = c(0,1,1),
177               seasonal = list(order = c(0,1,1), period = 4))
178 coeftest(model5)
179 cat("AIC model5 :", AIC(model5), "\n")
180 cat("BIC model5 :", BIC(model5), "\n\n")
181
182 model6 <- Arima(train_log, order = c(1,1,1),
183               seasonal = list(order = c(0,1,1), period = 4))
184 coeftest(model6)
185 cat("AIC model6 :", AIC(model6), "\n")
186 cat("BIC model6 :", BIC(model6), "\n\n")
187
188 model7 <- Arima(train_log, order = c(0,1,2),
189               seasonal = list(order = c(0,1,1), period = 4))
190 coeftest(model7)
191 cat("AIC model7 :", AIC(model7), "\n")
192 cat("BIC model7 :", BIC(model7), "\n\n")
193
194 # CHAPITRE 8 : VALIDATION
195 residus5 <- residuals(model5)
196 Box.test(residus5, type = "Box-Pierce", lag = 20)
197 Box.test(residus5, type = "Ljung-Box", lag = 20)
198 shapiro.test(as.numeric(residus5))
199
200 residus7 <- residuals(model7)
201 Box.test(residus7, type = "Box-Pierce", lag = 20)
202 Box.test(residus7, type = "Ljung-Box", lag = 20)
203 shapiro.test(as.numeric(residus7))
204
205 # CHAPITRE 9 : PREVISION
206 h <- length(test)
207 prev7 <- forecast(model7, h = h)
208 prev7_orig <- exp(prev7$mean)

```

```

209 test_orig <- as.numeric(test)
210
211 png("prevision_ukgas_orig.png", width = 800, height = 500)
212 plot(test_orig, type = "l", col = "black",
213       main = "Prevision vs Valeurs reelles UKgas",
214       xlab = "Temps",
215       ylab = "Consommation (millions de therms)",
216       ylim = range(c(test_orig, as.numeric(prev7_orig))))
217 lines(as.numeric(prev7_orig), col = "green", lwd = 2)
218 legend("topleft",
219       legend = c("Valeurs reelles", "Previsions"),
220       col = c("black", "green"), lwd = 2)
221 dev.off()
222
223 rmse <- sqrt(mean((test_orig - as.numeric(prev7_orig))^2))
224 mape <- mean(abs((test_orig - as.numeric(prev7_orig)) /
225               test_orig)) * 100
226 cat("RMSE :", rmse, "\n")
227 cat("MAPE :", mape, "%\n")

```